

Mise à jour calibration — 2026-07-05

La version recommandée pour l'analyse de survie BOAMP est maintenant le fichier `data/processed/boamp_phase2_survival_calibrated_balanced.csv`. Il contient 1 210 appels d'offre éligibles et 269 événements de réapparition proxy (22,2%, calibration Sentence-Transformer). La règle équilibrée est : similarité texte $\geq 0,50$, score composite $\geq 0,50$, fenêtre temporelle $W = 6$, correction des codes CPV génériques, sans seuil minimum sur la marge.

Les variantes conservées pour sensibilité sont : `boamp_phase2_survival_calibrated_broad.csv` (490 événements, 40,5%) et `boamp_phase2_survival_calibrated_strict.csv` (79 événements, 6,5%). Ces événements sont des récurrences proxy identifiées dans BOAMP, pas des renouvellements légalement certifiés.

1 DECP – Données Essentielles de la Commande Publique

1.1 Présentation générale

Le jeu de données DECP constitue la source complémentaire principale du projet. Introduit par le décret du 25 mars 2016, il impose à toute autorité publique attribuant un marché supérieur à 25 000 € de publier un enregistrement structuré sur `data.gouv.fr` dans les deux mois suivant la signature. Ces données sont consolidées par l'AIFE (Agence pour l'Informatique Financière de l'État) et mises à disposition sous la forme d'un fichier Parquet unique.

Contrairement au BOAMP, qui enregistre des *annonces*, le DECP enregistre le *contrat signé*. C'est donc la source de référence pour les champs nécessaires à l'analyse de survie (montant réel, durée déclarée, date de notification).

Fichier utilisé

La version exploitée n'est pas les fichiers JSON annuels officiels (dont la structure est inconsistante selon les millésimes) mais le fichier Parquet consolidé publié par le projet communautaire *decp-processing* sur `data.gouv.fr` (identifiant de ressource `11cea8e8-df3e-4ed1-932b-`). Ce fichier est enrichi par des jointures SIRENE, ce qui ajoute des colonnes géographiques (commune, département, région) absentes du DECP brut.

Volume et couverture

- Nombre total d'enregistrements : environ **3,1 millions** de lignes pour l'ensemble de la France et de tous les secteurs
- Granularité : un enregistrement correspond à un contrat (ou une modification de contrat)
- Couverture temporelle dense : à partir de **2019** (la publication était obligatoire depuis 2018 mais la couverture réelle est quasi nulle avant 2019)
- Corpus retenu après filtrage : **3 039 contrats** portant sur les marchés numériques en Pays de la Loire (2018–2024), uniquement les versions courantes (`donneesActuelles = True`)

Filtres appliqués pour constituer le corpus de travail

- Département de l'acheteur : 44, 49, 53, 72, 85 (Pays de la Loire)
- Code CPV : premiers chiffres dans {48, 72, 32, 35} (marchés numériques / informatiques)
- Année de notification : 2015 à 2024
- Version courante uniquement : `donneesActuelles = True` (élimine les modifications historiques en doublon)

1.2 Principales données récupérables

Les informations accessibles sont regroupées en plusieurs catégories.

Identification du contrat

- `uid` : identifiant unique global (concaténation de `acheteur_id` et `id`)
- `id` : identifiant attribué par l'acheteur (non unique globalement)
- `nature` : type de contrat (Marché, Accord-cadre, Marché subséquent...)
- `donneesActuelles` : booléen indiquant la version courante du contrat
- `sourceDataset` : plateforme d'origine de la publication (AIFE, PES, marchés-publics.info, e-marchespublics.com...)

Caractéristiques du marché

- `objet` : intitulé du marché (texte libre, plus concis que celui du BOAMP)
- `codeCPV` : code CPV principal ; format structuré, toujours présent
- `procedure` : libellé de la procédure standardisé (Procédure adaptée, Appel d'offres ouvert, Marché négocié...)
- `montant` : montant du contrat en euros ; champ obligatoire du DECP (couverture 98 % avant nettoyage)
- `offresRecues` : nombre d'offres reçues ; champ facultatif, présent dans 26 % des enregistrements du corpus

Informations temporelles

- `dateNotification` : date de notification du contrat signé ; champ obligatoire – c'est l'**origine temporelle** de l'analyse de survie
- `datePublicationDonnees` : date de publication en open data (peut être postérieure de plusieurs mois à la signature)
- `dureeMois` : durée déclarée du contrat en mois ; champ obligatoire (couverture 99 % dans le corpus)

Informations géographiques et sectorielles

- `lieuExecution_code` et `lieuExecution_typeCode` : code et type du lieu d'exécution (code postal, commune, département ou région)
- `acheteur_departement_code` : code du département de l'acheteur (enrichissement SIRENE) – utilisé pour le filtre géographique
- `acheteur_region_code` / `acheteur_region_nom` : région de l'acheteur (enrichissement SIRENE)

Acteurs

- `acheteur_id` : SIRET de l'acheteur (14 chiffres) ; **obligatoire** dans le DECP, couverture 100 %

- `acheteur_nom` : nom de l'acheteur (enrichissement SIRENE)
- `acheteur_categorie` : catégorie de l'acheteur (Commune, Groupement de communes, Département, Établissement hospitalier, EPIC...)
- `titulaire_id` : identifiant du titulaire (SIRET dans la plupart des cas)
- `titulaire_typeIdentifiant` : type d'identifiant du titulaire (SIRET, TVA, HORS-UE...)
- `titulaire_nom` : nom du titulaire (enrichissement SIRENE)

1.3 Comparaison de couverture avec le BOAMP

Champ	BOAMP	DECP	Source recommandée
SIRET acheteur	8 %	100 %	DECP
Montant (EUR)	43 %	93 %	DECP
Durée (mois)	34 %	99 %	DECP
Date notification	—	100 %	DECP
Texte du marché	100 %	100 %	BOAMP (plus riche)
Type d'avis	100 %	—	BOAMP
Liens de renouvellement	46 %	—	BOAMP (<code>annonce_lie</code>)

1.4 Exemple d'enregistrement DECP

```
{
  "uid" : "214401622000112024K-P0rgdsDS00",
  "id" : "2024K-P0rgdsDS00",
  "nature" : "Marché",
  "acheteur_id" : "21440162200011",
  "acheteur_nom" : "COMMUNE DE SAINT-HERBLAIN (MAIRIE)",
  "acheteur_departement_code" : "44",
  "acheteur_categorie" : "Commune",
  "titulaire_id" : "44905091600021",
  "titulaire_nom" : "AXIANS IDF",
  "objet" : "Infogérance du système d'information",
  "codeCPV" : "72000000",
  "procedure" : "Procédure adaptée",
  "montant" : 140000.0,
  "dureeMois" : 48.0,
  "dateNotification" : "2024-12-31",
  "datePublicationDonnees" : "2025-01-10",
  "offresRecues" : null,
  "donneesActuelles" : true,
  "sourceDataset" : "aife_dume"
}
```

Cas d'usage dans le projet

- Source principale pour l'analyse de survie : date de notification (origine), durée déclarée et montant

- Clé SIRET de l’acheteur pour le regroupement et le suivi longitudinal des contrats d’un même acheteur
- Base pour la construction de la variable cible de renouvellement via l’algorithme de liaison (`decpr_renewal_links.csv`)
- Enrichissement de la couverture géographique et sectorielle du corpus BOAMP (champs absents ou incomplets dans BOAMP legacy)

2 Jeux de données traités

Les données brutes issues du BOAMP et du DECP sont transformées par un pipeline de nettoyage (tâche 7) qui produit deux fichiers d’analyse prêts à l’emploi.

2.1 `boamp_clean.csv` – Échantillon BOAMP nettoyé

Contenu

Échantillon de **500 avis** BOAMP couvrant la période 2015–2024 en Pays de la Loire, domaine numérique (CPV 48 / 72 / 32 / 35), équilibrés à 50 avis par année et mixant les types d’avis (appels d’offres, attributions, etc.). Le fichier est le résultat de la mise à plat (*flatten*) du champ `donnees` et des transformations de nettoyage.

Volume et structure

- Dimensions : 500 lignes × 44 colonnes
- Format : CSV (séparateur virgule, encodage UTF-8)
- Couverture temporelle : 2015–2024 (50 avis par année)

Répartition des avis

- `APPEL_OFFRE` : 225 avis (45 %)
- `ATTRIBUTION` : 217 avis (43 %)
- `RECTIFICATIF` : 53 avis (11 %)
- `MODIFICATION` / `PRE-INFORMATION` : 5 avis (1 %)

Format des données dans `donnees`

- `donnees_format = legacy` : 460 avis (format BOAMP classique, clés françaises : `IDENTITE`, `OBJET`, `PROCEDURE...`)
- `donnees_format = eforms` : 40 avis (format UBL européen 2024, clé racine `EFORMS`, structure XML imbriquée)

Colonnes ajoutées lors du nettoyage

- `cpv_clean`, `cpv_full8`, `cpv_div2`, `cpv_group3`, `cpv_class4`, `cpv_category5`, `cpv_is_missing`, `cpv_is_generic` : code CPV normalisé (8 chiffres) et toute la hiérarchie – division (2), groupe (3), classe (4), catégorie (5 chiffres) – plus les indicateurs CPV manquant / générique
- `buyer_siret` : SIRET de l’acheteur extrait de `donnees` (disponible uniquement pour les avis eForms 2024 ; taux de renseignement : 8 %)
- `buyer_key` : clé canonique de l’acheteur – SIRET si disponible, sinon nom normalisé (minuscules, sans accents, sans suffixes juridiques)

- `amount_raw`, `flag_amount_zero`, `flag_amount_tiny`, `flag_amount_ceiling`, `amount_clean` : montant brut, indicateurs de valeurs aberrantes et montant nettoyé (taux de renseignement après nettoyage : 43 %)
- `duration_raw_boamp`, `flag_duration_suspect`, `duration_clean` : durée brute, indicateur et durée nettoyée (taux de renseignement après nettoyage : 34 %)
- `category_id`, `category_label` : identifiant et libellé de la catégorie technologique (cf. section 3)

Statistiques descriptives des champs quantitatifs

Indicateur	Montant (EUR)	Durée (mois)
Observations valides	215	171
Moyenne	814 356	29,4
Médiane	430 070	24,0
Min	3 648	1,0
Max	9 750 000	96,0

2.2 `decp_clean.csv` – Corpus DECP nettoyé

Contenu

Corpus filtré et nettoyé issu du fichier DECP Parquet, comprenant l'ensemble des contrats numériques en Pays de la Loire sur la période effective de couverture dense du DECP.

Volume et structure

- Dimensions : 3 039 lignes × 36 colonnes
- Format : CSV (séparateur virgule, encodage UTF-8)
- Couverture temporelle : 2018–2024 (couverture dense à partir de 2019 : 361, 433, 506, 574, 561 et 562 contrats par année de 2019 à 2024)

Répartition par nature de contrat

- Marchés : 1 696 (55,8 %)
- Accords-cadres : 1 241 (40,8 %)
- Marchés subséquents : 99 (3,3 %)
- Autres : 3 (0,1 %)

Répartition géographique

- Loire-Atlantique (44) : 1 438 contrats (47 %)
- Maine-et-Loire (49) : 528 contrats (17 %)
- Sarthe (72) : 508 contrats (17 %)
- Vendée (85) : 362 contrats (12 %)
- Mayenne (53) : 203 contrats (7 %)

Principales procédures observées

- Procédure adaptée (MAPA) : 1 201 contrats (39 %)
- Appel d'offres ouvert : 749 contrats (25 %)
- Marché négocié sans publicité : 220 contrats (7 %)

- Marché passé sans publicité ni mise en concurrence : 163 contrats (5 %)
- Autres : 706 contrats (23 %)

Colonnes ajoutées lors du nettoyage

Les mêmes transformations que pour `boamp_clean.csv` sont appliquées :

- `buyer_key` : clé canonique de l'acheteur – toujours un SIRET dans le DECP (100 % de couverture sur `acheteur_id`)
- `cpv_clean`, `cpv_div2`, `cpv_class4` : code CPV normalisé et agrégats hiérarchiques
- `amount_raw`, `flag_amount_zero`, `flag_amount_tiny`, `flag_amount_ceiling`, `amount_clean` : montant nettoyé (taux de renseignement : 93 %)
- `duration_raw_decp`, `flag_duration_suspect`, `duration_clean` : durée nettoyée (taux de renseignement : 99 %)
- `category_id`, `category_label` : catégorie technologique (cf. section 3)

Statistiques descriptives des champs quantitatifs

Indicateur	Montant (EUR)	Durée (mois)
Observations valides	2 830	3 014
Moyenne	358 142	38,2
Médiane	102 382	48,0
1 ^{er} quartile	49 746	24,0
3 ^e quartile	240 000	48,0
Min	1 000	1,0
Max	9 750 000	120,0
Mode de la durée	—	48,0

2.3 Règles de nettoyage communes aux deux sources

Normalisation de la clé acheteur (`buyer_key`)

- **Priorité 1 – SIRET** : si un identifiant numérique de 14 chiffres est disponible, la clé est `SIRET:{14 chiffres}`
- **Priorité 2 – Nom normalisé** : minuscules, suppression des accents, suppression de la ponctuation, suppression des suffixes juridiques (SARL, SA, SAS, Commune de, Mairie de, SDIS, CHU...); la clé est `NAME:{nom normalisé}`
- Table de correspondance inter-sources : `buyer_bridge.csv` (461 clés canoniques uniques, dont 303 ancrées sur un SIRET)

Nettoyage des montants

- `flag_amount_zero` : valeur = 0 (artefact d'encodage)
- `flag_amount_tiny` : $0 < \text{valeur} < 1\,000\text{ €}$ (implausible pour un marché numérique)
- `flag_amount_ceiling` : valeur $\geq 10\,000\,000\text{ €}$ (vraisemblablement un plafond d'accord-cadre, non le prix réel)
- `amount_clean` : NaN si l'un des trois indicateurs est vrai ; sinon valeur originale (aucune suppression des données brutes)

Nettoyage des durées

- `flag_duration_suspect` : durée hors de l'intervalle [1, 120] mois
- `duration_clean` : NaN si l'indicateur est vrai, sinon valeur originale
- Résultats : 0 valeurs suspectes dans DECP ; quelques valeurs suspectes dans BOAMP (durées déclarées en jours mal converties)

3 Taxonomie sectorielle (`taxonomy.csv`)

Présentation

Le fichier `taxonomy.csv` définit un référentiel de **10 catégories technologiques** permettant de regrouper les marchés numériques au-delà des codes CPV bruts (dont il existe environ 9 000 valeurs distinctes). Il est utilisé lors de la tâche 7 pour annoter chaque contrat avec un libellé métier cohérent, aussi bien dans `boamp_clean.csv` que dans `decp_clean.csv`.

Logique d'affectation

1. Correspondance CPV : le préfixe du code CPV normalisé est comparé aux préfixes de chaque catégorie ; le préfixe le plus long gagne (*longest prefix match*)
2. Repli textuel : si aucun préfixe CPV ne correspond, une recherche de mots-clés (insensible à la casse) est effectuée dans le champ `objet`
3. Valeur par défaut : `CAT_UNKNOWN` / *Unknown*

Référentiel des catégories

ID	Libellé	Division CPV	Préfixes CPV
CAT01	Software & Applications	48	48
CAT02	IT Services & Consulting	72	72
CAT03	Cybersecurity	35	35, 72250, 72310, 72315
CAT04	Telecom & Networks	32	32
CAT05	Cloud & Infrastructure	48800	48800, 72250, 72310
CAT06	IT Hardware & Equipment	30	30, 32420
CAT07	Digital Workplace & Collaboration	48500	48500, 72212, 64200
CAT08	Data & AI	72300	72300, 72322, 72316
CAT09	GIS & Mapping	72320	72320, 38221
CAT10	IT Maintenance & Support	50300	50300, 72250, 72611

Distribution des catégories dans le corpus

Catégorie	BOAMP (500)	DECP (3 039)
IT Services & Consulting	167 (33 %)	1 321 (43 %)
Software & Applications	88 (18 %)	608 (20 %)
Telecom & Networks	80 (16 %)	581 (19 %)
Cybersecurity	63 (13 %)	337 (11 %)
Digital Workplace & Collaboration	28 (6 %)	110 (4 %)
Unknown	37 (7 %)	0 (0 %)
Autres (CAT05–CAT10)	37 (7 %)	82 (3 %)

Limites connues

- Les codes CPV génériques (ex. 72000000, division entière) ne sont pas distingués par le repli textuel si l’objet du marché est trop court ou générique ; ils tombent dans **Unknown**
- Certaines catégories sont proches (CAT03 Cybersecurity, CAT05 Cloud) et partagent des préfixes CPV : la règle du *longest prefix* tranche, mais peut induire des erreurs sur les marchés transverses

4 Liens de renouvellement (decp_renewal_links.csv)

Présentation

Ce fichier est le **jeu de données cible** pour l’analyse de survie. Il contient, pour chaque contrat du corpus DECP nettoyé, soit la durée observée jusqu’au renouvellement (événement), soit la durée censurée jusqu’à la fin d’étude (31 décembre 2024).

Ni le BOAMP ni le DECP ne fournissent de champ **renewal_of** direct. Le lien doit donc être reconstruit algorithmiquement.

Volume et structure

- Dimensions : 3 039 lignes $\times$ 13 colonnes (une ligne par contrat du corpus **decp_clean.csv**)
- Format : CSV (séparateur virgule, encodage UTF-8)

Principales données

- **uid** : identifiant unique du contrat source (clé de jointure vers **decp_clean.csv**)
- **acheteur_id** : SIRET de l’acheteur
- **cpv_div2** : division CPV (2 chiffres) utilisée pour le regroupement
- **source_date_notification** : date de notification du contrat source (point zéro de la durée observée)
- **declared_duration_months** : durée déclarée (fallback : 24 mois si absente ou invalide)
- **renewal_uid** : identifiant du contrat de renouvellement identifié ; **null** si censuré
- **event** : 1 si un renouvellement a été trouvé, 0 sinon
- **observed_duration_months** : durée observée en mois – durée jusqu’au renouvellement si **event**=1, durée jusqu’au 31/12/2024 si censuré
- **gap_months** : écart en mois entre la date de notification du contrat source et celle du renouvellement
- **text_similarity** : similarité de Jaccard sur les tokens des champs **objet** des deux contrats
- **match_score** : score composite de correspondance ($0,7 \times$ similarité textuelle $+ 0,3 \times$ proximité temporelle)
- **is_censored** : 1 si aucun renouvellement trouvé (complément de **event**)
- **censoring_date** : date de censure (31/12/2024) pour les observations censurées

Algorithme de liaison (prototype, semaine 3)

La liaison est effectuée groupe par groupe : pour chaque paire (acheteur, division CPV), les contrats sont triés par date, et pour chaque contrat source on recherche un contrat

candidat B vérifiant simultanément :

1. $\text{dateNotification}(B) > \text{dateNotification}(\text{source})$
2. $|\text{gap}(B) - \text{dureeMois}(\text{source})| \leq 6 \text{ mois}$ (fenêtre temporelle de ± 6 mois autour de la durée déclarée)
3. $\text{Jaccard}(\text{objet source}, \text{objet } B) \geq 0,30$

Si plusieurs candidats passent ces filtres, le meilleur est sélectionné par le score composite décrit ci-dessus.

Résultats du prototype

Indicateur	Valeur
Contrats analysés	3 039
Renouvellements liés (événements)	252 (8,3 %)
Contrats censurés	2 787 (91,7 %)
Durée médiane observée (tous)	30,9 mois
Durée médiane observée (événements)	33,8 mois
Similarité textuelle médiane (événements)	0,60

Limites et perspectives

- Taux de liaison actuel (8,3 %) est un **prototype de référence** ; la cible est 40–60 % après amélioration
- Piste 1 : affiner le regroupement par classe CPV à 4 chiffres plutôt que 2 (plus précis, réduira les faux positifs inter-catégories)
- Piste 2 : contrainte un-à-un (chaque contrat source ne peut être lié qu'à un seul renouvellement, et vice-versa)
- Piste 3 : évaluation manuelle de la précision et du rappel sur un échantillon de 50 paires, pour calibrer les seuils de similarité et de fenêtre temporelle
- Piste 4 : exploiter le champ BOAMP `annonce_lie` pour les contrats croisables entre les deux sources